KI/SZZPP Aplikovaná informatika: povinný základ

Základy zpracování dat

1. Přehled požadovaných znalostí a dovedností

Obecně se požaduje schopnost tvorby skriptů a reportů (notebooky, prezentace) v jazyce R se zaměřením na zpracování datových tabulek (`data.frame`) a vizualizaci dat. Následuje přehled konkrétních znalostí a dovedností:
základní datové typy (`numeric`, `logical`, `character`, `factor`) a datové struktury (vektory, matice, datové tabulky, seznam)

- základní logické a matematické operace
- operace nad řetězci včetně využití jednoduchých regulárních výrazů
- načítání a ukládání dat (CSV, XLSX)
- cykly a podmíněné příkazy
- tvorba vlastních funkcí a skriptů
- manipulace s datovými tabulkami (různé úpravy a transformace, výběr, řazení, filtrování, slučování, seskupování a sumarizace, převod mezi krátkým a dlouhým formátem, kontingenční tabulky)
- tvorba základních i pokročilých typů grafů (včetně histogramů a boxplotů) a jejich interpretace
- tvorba reprodukovatelných reportů (Rmd, qmd)

2. Obecná charakteristika zkušební úlohy

Vstupem je:

- sada tabulek ve formátu CSV nebo XLSX
- seznam požadavků na jejich zpracování

Výstupem je protokol s následujícími požadavky:

- formát: Rmd nebo qmd soubor (notebook nebo prezentace) spolu s vyrenderovaným HTML nebo PDF souborem
- obsah:
    - základní popis zadaných dat a popis dílčích operací použitých při jejich zpracování
    - komentovaný kód
    - interpretace získaných výsledků

3. Ukázková úloha

V adresáři … naleznete soubor **`StudentsPerformance.csv`**. Soubor načtěte a vyřešte následující úkoly:

- vytvořte nový sloupec `avg.score`, který bude pro každý záznam tabulky obsahovat průměrné skóre dané osoby ze sloupců `math.score`, `reading.score` a `writing.score`,
- z tabulky vyfiltrujte pouze záznamy, kde sloupec `parental.level.of.education` obsahuje pojem “high school” kdekoliv v textu,
- vypočtěte průměrnou hodnotu sloupce `avg.score` pro každou kombinaci kategorií `gender` a `race.ethnicity`,
- tabulku upravte do tzv. “širokého formátu” tak, aby kategorie ze sloupce `gender` představovaly vlastní sloupce a vypočtené průměrné hodnoty byly hodnotami v těchto nových sloupcích,
- pro každou kategorii ze sloupce `race.ethnicity` vytvořte boxplot ze sloupce `avg.score`.

Vypracujte protokol s řešením ve formátu Rmd nebo qmd spolu s vyrenderovaným HTML nebo PDF souborem. V protokolu charakterizujte data ve vstupním souboru, popište svůj postup práce a interpretujte získané výsledky. Součástí protokolu je komentovaný kód.

4. Seznam dostupných materiálů a technologií

- počítač s nainstalovaným interpretem jazyka R a nejčastěji používanými balíčky (tidyverse) a vývojovým prostředím RStudio
- následující materiály:
  - https://oeconomica.vse.cz/wp-content/uploads/Danko_Safr_R-snadno-a-rychle_1.pdf
  - https://oeconomica.vse.cz/wp-content/uploads/Safr_Danko_R-snadno-a-rychle_2.pdf
  - taháky:
    - https://images.datacamp.com/image/upload/v1697642178/Marketing/Blog/R_Cheat_Sheet_PNG_1.pdf
    - https://images.datacamp.com/image/upload/v1697797990/Marketing/Blog/Markdown_Cheat_Sheet.pdf
    - https://images.datacamp.com/image/upload/v1671098754/Marketing/Blog/Working_With_Text_Data_in_R.pdf
    - https://images.datacamp.com/image/upload/v1660300796/Marketing/Blog/Manipulating_Data_in_dplyr_Cheat_Sheet.pdf
    - https://images.datacamp.com/image/upload/v1666806657/Marketing/Blog/ggplot2_cheat_sheet.pdf