KI/SZZVP Aplikovaná informatika: volitelné bloky
Databázové systémy a zpracování dat

I. Relační databázové systémy a OLAP databáze 1
II. NoSQL databáze 2
III. Pokročilé statistické metody a zpracování časových řad 3
IV. Úvod do strojového učení 4
V. Počítačové zpracování signálu 5

I. Relační databázové systémy a OLAP databáze

1. Přehled požadovaných znalostí a dovedností

- konceptuální návrh: entity, atributy, relační vztahy (pasivně)
- logický návrh: relace 1:1, 1:N, M:N a jejich rozklad, normalizace (1-3 normální forma), E-R diagram (vraní nohy)
- fyzický návrh: příkaz CREATE TABLE, základní domény (číselné, řetězcové, časové), základní omezení (primární a cizí klíče, NOT NULL, UNIQUE)
- manipulace s daty: vkládání INSERT INTO
- dotazy: příkaz SELECT, vnitřní a vnější spojení (FROM [INNER/LEFT/RIGHT] JOIN), selekce (WHERE), projekce (SELECT)
- řazení (ORDER BY)
- seskupování (GROUP BY)
- transakce
- **analytické funkce**
- **uložené procedury (včetně triggerů)**
- **rekurzivní dotazy**
- **programový přístup k databázím (kurzory, ORM)**
- **jednoduché vizualizační nástroje (Matplotlib)**
- **OLAP přístup a druhy OLAP (ROLAP, MOLAP a HOLAP)**
- **základní principy a odlišnosti systémů OLTP a OLAP**
- **architektura multidimenzionálních OLAP databází (fakta a dimenze)**
- **architektura datových modelů OLAP (star, snowflake)**
- **datové sklady (DW) a datová tržiště (DM)**
- **klientský reporting**
- **plánování projektu tvorby datového úložiště**

2. Obecná charakteristika zkušební úlohy

- návrh optimálního logického relačního modelu pro Open Data získaná z Internetu
- vytvoření databáze v PostgreSQL
- programové načtení dat do databáze
- vizualizace dat z databáze nebo jednoduchá aplikace (skript) zpřístupňující data
- návrh multidimenzionálního modelu struktury datového skladu pro data

výstupy:
- ER diagram a DM diagram
- skripty

- přehledné výstupy (agregace dat)
- vizualizace

3. Ukázková úloha

Propojení a vizualizace dat ze dvou datových zdrojů:
- Cizinci podle státního občanství, věku a pohlaví – rok 2019
- HDP na hlavu pro jednotlivé státy (lze samozřejmě použít i jiný relevantní zdroj)

klíčové fáze řešení:
- návrh struktury databáze (ER-diagram)
- vytvoření příslušných tabulek a relací
- vytvoření skriptu pro zpracování externích zdrojů a jejich vložení do databáze (včetně řešení nekonzistencí identifikátorů, chybějících dat apod.)
- spojení tabulek (JOIN)
- návrh a implementace dotazů

doporučený výstup:
- seskupení dat podle roků, státního občanství
- seskupení dat cizinců podle HDP na hlavu v zemích, kde mají státní občanství
- jednoduchá vizualizace výsledků
- návrh struktury datového skladu

4. Seznam dostupných materiálů a technologií

K dispozici bude Docker kontejner s oficiálním obrazem databázového systému PostgreSQL + Python s běžnými nástroji pro zpracování dat (NumPy, Pandas) + klient DBeaver.

II. NoSQL databáze

1. Přehled požadovaných znalostí a dovedností

- dokumentově orientované databázové systémy (MongoDB, BJSON v PostgreSQL)
- programové vytváření a plnění
- dotazy nad databází
- agregační pipelines
- jednoduché vizualizační nástroje (Matplotlib)

2. Obecná charakteristika zkušební úlohy

- návrh optimálního NoSQL modelu pro Open Data získaná z Internetu (zdůvodnění, proč je či není vhodné zvolit SQL databázi)
- vytvoření databáze v MongoDB
- programové načtení dat do databáze
- vizualizace dat z databáze nebo jednoduchá aplikace (skript) zpřístupňující data

výstupy:
- hodnocení výhod/nevýhod NoSQL řešení
- skripty
- přehledné výstupy (agregace dat)
- vizualizace

3. Ukázková úloha

Propojení a vizualizace dat ze dvou datových zdrojů:

- Cizinci podle státního občanství, věku a pohlaví – rok 2019
- HDP na hlavu pro jednotlivé státy (lze samozřejmě použít i jiný relevantní zdroj)

klíčové fáze řešení:

- návrh struktury záznamů pro dokumentově orientovanou databázi (*MongoDB*)
- vytvoření skriptu pro zpracování externích zdrojů a jejich vložení do databáze (včetně řešení nekonzistencí identifikátorů, chybějících dat apod.)
- denormalizace
- návrh a implementace dotazů (preferovány jsou agregační operace)

doporučený výstup (samozřejmě lze doplnit další):

- seskupení dat podle roků, státního občanství
- seskupení dat cizinců podle HDP na hlavu v zemích, kde mají státní občanství
- jednoduchá vizualizace výsledků

4. Seznam dostupných materiálů a technologií

K dispozici bude Docker kontejner s oficiálním obrazem databázového systému MongoDB + Python s běžnými nástroji pro zpracování dat (NumPy, Pandas).

III. Pokročilé statistické metody a zpracování časových řad

1. Přehled požadovaných znalostí a dovedností

- jednoduchá a mnohonásobná lineární regrese
- nelineární regresní modely
- analýza rozptylu
- logistická regrese
- předpoklady regresních modelů a co dělat, když nejsou splněny
- dekompozice časových řad - hledání sezónnosti a časového trendu
- Box-Jenkinsova metodologie: modely ARMA, ARIMA, SARIMA
- dynamické lineární modely závislosti mezi časovými řadami

2. Obecná charakteristika zkušební úlohy

- zkouška má ověřit znalosti vybraných metod a schopnost je aplikovat na reálná data
- **vstup**: datový soubor a úkol k řešení
- **výstup**: report (R nebo Python) obsahující analýzy, vizualizace a především interpretace, aby bylo zřejmé, jaké metody a proč byly použity a jaké jsou závěry vzhledem k řešenému úkolu
- **postup práce**:
  - na základě typu dat a daného úkolu rozmyslet, jaké metody je možné použít
  - vizualizace dat a včetně komentáře, co je zřejmé a co se dá očekávat na výstupu z analýz
  - aplikace vybraných metod, odhady modelů, hodnocení jejich kvality, kontrola předpokladů
  - interpretace výsledků, závěr vzhledem k zadanému úkolu

3. Ukázková úloha

Zadání: Cílem je najít optimální model pro výšku hladiny v řece (na čem a jakým způsobem výška hladiny závisí). K dispozici jsou data o různých ukazatelích, která mohou mít na výšku hladiny vliv.

Postup: Nejprve je potřeba zhodnotit, zda máme k dispozici časovou řadu, nebo nezávislá pozorování a podle toho vybrat modely, které bude možné na data aplikovat (modely časových řad nebo klasické regresní modely). Dále je potřeba identifikovat závisle proměnnou, případně podle jejího charakteru upřesnit volbu modelů (klasická nebo logistická regrese).
Vizualizace by měla zahrnovat zobrazení samotného průběhu závisle proměnné a vykreslení vhodných grafů závislostí na ostatních proměnných v databázi (bodové grafy pro nezávislá měření, korelační funkce pro časové řady). Následuje stručná interpretace těchto grafů – které závislosti je možné očekávat, jsou-li v datech závislé regresory, atd.
Po úvodním popisu dat se přistoupí k vlastním analýzám. Student by měl navrhnout více modelů, které bude hodnotit a dále porovnávat. Např. u časových řad je možné vyzkoušet modely pro samostatnou časovou řadu: model trendu a sezónnosti, SARIMA model, nebo model závislosti na ostatních řadách v souboru. Pro nezávislá pozorování se porovnávají různé regresní závislosti na různých skupinách proměnných, uvažuje se lineární i polynomická regrese (pokud je vhodná), uvažují se modely s interakcemi i bez nich, využívá se kroková regrese. Ke každému modelu se vypočte indikátor kvality modelu, což může být např. Akaikeho nebo Bayesovské kriterium, procento vysvětlené variability, významnost koeficientů, střední chyba residuí. U každého modelu je také třeba kontrolovat splnění předpokladů (zejména nezávislost a normalita residuí a stabilita rozptylu), a pokud předpoklady nejsou splněny, tak učinit potřebné nápravné kroky (např. při závislých residuích u časových řad přidat členy ARMA modelů, při nestabilním rozptylu či nenormálních residuích logaritmovat závisle proměnnou, atd.).
V posledním kroku se interpretují výsledky, tj. slovně se popíše porovnání modelů, který je lepší/horší a proč a vybere se optimální model. U něj se ohodnotí jeho kvalita: jak dobře sedí na data, kolik variability se jím vysvětlí, jak dobré predikce je možné očekávat. Student musí umět model zapsat formou rovnice, popsat způsob, jakým jednotlivé faktory v modelu ovlivňují závisle proměnnou, které jsou pro chování závisle proměnné klíčové, atd.

4. Seznam dostupných materiálů a technologií

Prostředí pro R a Python

IV. Úvod do strojového učení

1. Přehled požadovaných znalostí a dovedností

- znalost přípravy dat a datasetů: nahrazení chybějících atributů, práce s kategorickými daty, normalizace/standardizace dat, redukce dimenzionality – PCA, LDA
- znalost metody a metrik pro hodnocení klasifikace a regrese včetně jejich použití: accuracy, senzitivita, specificita, F1-skóre, matice záměn, MSE, MAE apod.
- přehled klasických algoritmů pro klasifikaci a regresi v knihovně scikit-learn včetně jejich použití, znalost jejich základního principu a vlivu některých jejich hyperparametrů (např. pro regularizaci, jádrovou transformaci): rozhodovací a regresní stromy a lesy, metoda SVM a její klony (SVC, SVM, linear SVM), logistická regrese
- schopnost používat pokročilé nástroje knihovny scikit-learn: train-test split, pipes, vícenásobná validace, hledání hyperparametrů
- znalost základních modelů neuronových sítí: model MLP, konvoluční neuronové sítě, včetně výběru aktivačních funkcí; schopnost implementace těchto modelů za použití vysokoúrovňových frameworků např. Keras, PyTorch

2. Obecná charakteristika zkušební úlohy

- příprava datové sady – čištění dat
- stručná analýza datové sady včetně jejího vizuálního a statistického posouzení (anomálie, vyrovnanost tříd apod.)

- návrh a tvorba několika klasifikačních/regresních modelů
- zhodnocení dosažených výsledků za pomoci vhodných metrik a výběr perspektivního modelu

výstupy:

- vytvořený protokol (Jupyter sheet) obsahující jak zdrojové kódy, tak i vizualizace a tabulkové hodnoty

3. Ukázková úloha

Uvažujte dataset https://archive.ics.uci.edu/dataset/9/auto+mpg

1. Data vyčistěte a proveďte jejich analýzu (jednoduchá popisná statistika).
   - Diskutujte případnou úpravu dat – nahrazení chybějících a odlehlých hodnot atd.
   - Proveďte analýzu důležitosti příznaků např. pomocí metody PCA, nebo pomocí *random forests*, případně pomocí techniky *permutation feature importance*, vše je implementováno v knihovně *scikit-learn*.
2. Z klasických metod strojového učení (lineární regrese, SVR, random forests apod.) vyberte vhodný regresní model pro regresi veličiny MPG (spotřeba – miles per gallon). Pro každý z modelů nalezněte vhodné hyperparametry modelu.
3. Navrhněte jednoduchý (!) regresní model typu MLP, taktéž optimalizujte jeho hyperparametry (vrstvy, aktivační funkce apod.)
4. Porovnejte vytvořené modely a prezentujte přehlednou formou dosažené výsledky.

4. Seznam dostupných materiálů a technologií

Prostřední pro Python včetně všech výše uvedených knihoven (Pandas; scikit-learn, Keras, PyTorch).

V. Počítačové zpracování signálu

1. Přehled požadovaných znalostí a dovedností

- znalost základních charakteristik signálu (frekvence, amplituda, fáze)
- znalost metod zpracování signálu v časové oblasti (konvoluce, korelace, kovariance)
- znalost metod zpracování signálu ve frekvenční oblasti (Fourierova transformace)
- znalost technik pro posílení signálu v časové oblasti
- znalost technik pro filtraci šumu ve frekvenčním spektru
- základní práce s NumPy poli
- výpočet základních vlastností signálu v časové oblasti (perioda, amplituda, práce signálu, energie, trend apod.)
- výpočet frekvenčního spektra signálu
- využití vestavěných funkcí NumPy a SciPy

2. Obecná charakteristika zkušební úlohy

- práce s daty včetně načtení dat ze specializovaných formátů
- vytvoření postupu pro detekci událostí v signálech
- otestování postupů a identifikace jeho slabých a silných stránek
- vizualizace výstupů včetně diskuse

výstupy:

- graf vývoje tepové frekvence v závislosti na čase pro jeden vybraný signál
- přehledový graf závislosti tepové frekvence na signálu v databázi
- graf shody mezi navržených schématem pro výpočet tepové frekvence a daty v databázi

3. Ukázková úloha

Určete tepovou frekvenci z EKG signálu z veřejně dostupné databáze.

klíčové fáze řešení:

- načtení dat ve specializovaném formátu z veřejně dostupné databáze
- provedení základních operací se signály (filtrace, detrendování apod.)
- detekce určených událostí v signálech (R vrchol)
- výpočet tepové frekvence

doporučený výstup:

- Jupyter notebook s kódem a vysvětlujícími komentáři k jednotlivým krokům řešení a získaným výstupům (viz grafy níže)
- graf zobrazující tepovou frekvenci v závislosti na průběhu signálu
- graf zobrazující tepovou frekvenci ze všech signálů v databázi

4. Seznam dostupných materiálů a technologií

Jazyk Python s běžnými nástroji pro zpracování dat (NumPy, SciPy), nástroje pro načtení signálů z veřejně dostupné databáze, data z veřejně dostupné databáze